# Laboratorium Analizy Procesów Uczenia.

Data wykonania ćwiczenia:	10.05.2024	
Rok studiów:	1	
Semestr:	1	
Grupa studencka:	1b	
Grupa laboratoryjna:	-	

Ćwiczenie nr

Temat: Uczenie głębokie w R i Python. Klasyfikator obrazów za pomocą Keras.

5

Osoby wykonujące ćwiczenia:

1. Gracjan Wackermann

Katedra Informatyki i Automatyki

#### 1. Cel ćwiczenia:

Celem jest uczenie głębokie za pomocą, R i pakietu Keras.

# 2. Zadanie do wykonania:

Zadanie dotyczy sieci głębokiej w celu klasyfikacji obrazów pobranych ze zbioru danych.

# MNIST database of handwritten digits

- Wariant nr. 3 -

#### Uzyskany kod:

```
import numpy as np
from tensorflow import keras
from keras import layers
import matplotlib.pyplot as plt
# Wczytanie danych MNIST
(x train, y train), (x test, y test) =
keras.datasets.mnist.load data()
# Sprawdzenie kształtu danych
print(f"x train shape: {x train.shape}")
print(f"{x train.shape[0]} train samples")
print(f"{x test.shape[0]} test samples")
# Skalowanie obrazów do zakresu [0, 1]
x train = x train.astype("float32") / 255
x test = x test.astype("float32") / 255
# Upewnienie się, że obrazy mają kształt (28, 28, 1)
x train = np.expand dims(x train, -1)
x \text{ test} = \text{np.expand dims}(x \text{ test, } -1)
# Konwersja etykiet na macierze binarne klas
num classes = 10
y train = keras.utils.to categorical(y train, num classes)
y test = keras.utils.to categorical(y test, num classes)
# Architektura modelu
model = keras.Sequential([
    keras.Input(shape=(28, 28, 1)),
    layers.Conv2D(32, kernel size=(3, 3), activation="relu"),
    layers.MaxPooling2D(pool size=(2, 2)),
```

```
layers.Conv2D(64, kernel size=(3, 3), activation="relu"),
    layers.MaxPooling2D(pool size=(2, 2)),
    layers.Flatten(),
    layers. Dropout (0.5),
    layers.Dense(num classes, activation="softmax")
])
# Wyświetlenie podsumowania modelu
model.summary()
# Kompilowanie modelu
model.compile(
    loss="categorical crossentropy",
    optimizer="adam",
    metrics=["accuracy"]
)
# Trenowanie modelu
batch size = 128
epochs = 15
history = model.fit(
    x train, y train,
    batch size=batch size,
    epochs=epochs,
    validation split=0.1
)
# Ocena modelu na zbiorze testowym
score = model.evaluate(x_test, y_test, verbose=0)
print(f"Test loss: {score[0]}")
print(f"Test accuracy: {score[1]}")
# Prognozowanie nowych danych
predictions = model.predict(x test)
# Wyświetlenie przykładowego obrazu z jego przewidywaną klasą
plt.figure(figsize=(10, 5))
for i in range (10):
    plt.subplot(2, 5, i+1)
    plt.imshow(x test[i].reshape(28, 28), cmap='gray')
    plt.title(f"Label: {np.argmax(y test[i])}\nPred:
{np.argmax(predictions[i])}")
    plt.axis('off')
plt.show()
```

#### Wyniki z konsol:

x\_train shape: (60000, 28, 28) 60000 train samples

100000 test samples
100000 test samples
2024-06-13 11:11:44.997973: I tensorflow/core/platform/cpu\_feature\_guard.cc:210] This TensorFlow binary is optimized to use available CPU instructions in performance-critical operations.
To enable the following instructions: AVX2 FMA, in other operations, rebuild TensorFlow with the appropriate compiler flags.
Model: "sequential"


Layer (type)	Output Shape	Param #
conv2d (Conv2D)	(None, 26, 26, 32)	320
max_pooling2d (MaxPooling2D)	(None, 13, 13, 32)	0
conv2d_1 (Conv2D)	(None, 11, 11, 64)	18,496
max_pooling2d_1 (MaxPooling2D)	(None, 5, 5, 64)	0
flatten (Flatten)	(None, 1600)	0
dropout (Dropout)	(None, 1600)	0
dense (Dense)	(None, 10)	16,010

Total params: 34,826 (136.04 KB)
Trainable params: 34,826 (136.04 KB)
Non-trainable params: 0 (0.00 B)

```
Epoch 1/15
422/422
                             8s 17ms/step - accuracy: 0.7695 - loss: 0.7543 - val_accuracy: 0.9775 - val_loss: 0.0823
Epoch 2/15
422/422
                             7s 16ms/step - accuracy: 0.9614 - loss: 0.1229 - val_accuracy: 0.9858 - val_loss: 0.0567
Epoch 3/15
422/422
                             8s 19ms/step - accuracy: 0.9742 - loss: 0.0866 - val accuracy: 0.9867 - val loss: 0.0466
Epoch 4/15
422/422 -
                            · 8s 18ms/step - accuracy: 0.9780 - loss: 0.0739 - val_accuracy: 0.9880 - val_loss: 0.0440
Epoch 5/15
                           - 8s 19ms/step - accuracy: 0.9811 - loss: 0.0599 - val_accuracy: 0.9908 - val_loss: 0.0371
422/422 -
Epoch 6/15
422/422
                            8s 19ms/step - accuracy: 0.9830 - loss: 0.0557 - val accuracy: 0.9910 - val loss: 0.0373
Epoch 7/15
422/422

    8s 20ms/step - accuracy: 0.9849 - loss: 0.0489 - val accuracy: 0.9900 - val loss: 0.0346

Epoch 8/15
422/422
                           - 7s 16ms/step - accuracy: 0.9855 - loss: 0.0475 - val_accuracy: 0.9913 - val_loss: 0.0315
Epoch 9/15
422/422 -
                           8s 18ms/step - accuracy: 0.9862 - loss: 0.0440 - val_accuracy: 0.9928 - val_loss: 0.0291
Epoch 10/15
                            · 8s 20ms/step - accuracy: 0.9853 - loss: 0.0451 - val_accuracy: 0.9925 - val_loss: 0.0307
422/422
Epoch 11/15
422/422
                            8s 20ms/step - accuracy: 0.9878 - loss: 0.0383 - val accuracy: 0.9920 - val loss: 0.0319
Epoch 12/15
                           - 7s 17ms/step - accuracy: 0.9868 - loss: 0.0411 - val accuracy: 0.9932 - val loss: 0.0283
422/422
Epoch 13/15
422/422
                           - 7s 17ms/step - accuracy: 0.9893 - loss: 0.0345 - val accuracy: 0.9917 - val loss: 0.0321
Epoch 14/15
422/422 -
                           - 7s 17ms/step - accuracy: 0.9895 - loss: 0.0310 - val_accuracy: 0.9923 - val_loss: 0.0290
Epoch 15/15
422/422 -
                           - 7s 16ms/step - accuracy: 0.9888 - loss: 0.0330 - val accuracy: 0.9900 - val loss: 0.0320
Test loss: 0.027467403560876846
Test accuracy: 0.9918000102043152
313/313 •
                            1s 3ms/step
```



## **☆** ♦ ♦ **♦** Q 至 🖺

## 3. Wnioski:

- Na zajęciach poznaliśmy sposoby na konstruowanie sieci głębokiej w celu klasyfikacji obrazów pobranych ze zbioru danych. Uzyskany model trafnie rozróżnia ręcznie napisane liczby i przypisuje do nich poprawne etykiety. Dowodzi to poprawności działania kodu.

Link do repozytorium: https://github.com/fireinx/apu